第10章 事务与恢复

金培权（jpq@ustc.edu.cn）

Part 2: 故障恢复

金培权（jpq@ustc.edu.cn）

一、数据库保护技术概述

- **数据库保护**：预防各种对数据库的干扰破坏，确保数据安全可靠，以及在数据库遭到破坏后尽快地恢复
  - 乐观机制：事后恢复
  - 悲观机制：事前预防
- 数据库保护通过四个方面来实现
  - 完整性控制技术
    - Enable constraints
  - 安全性控制技术
    - Authorization and authentication
  - 数据库的恢复技术
    - Deal with failure
  - 并发控制技术
    - Deal with data sharing

DBMS架构

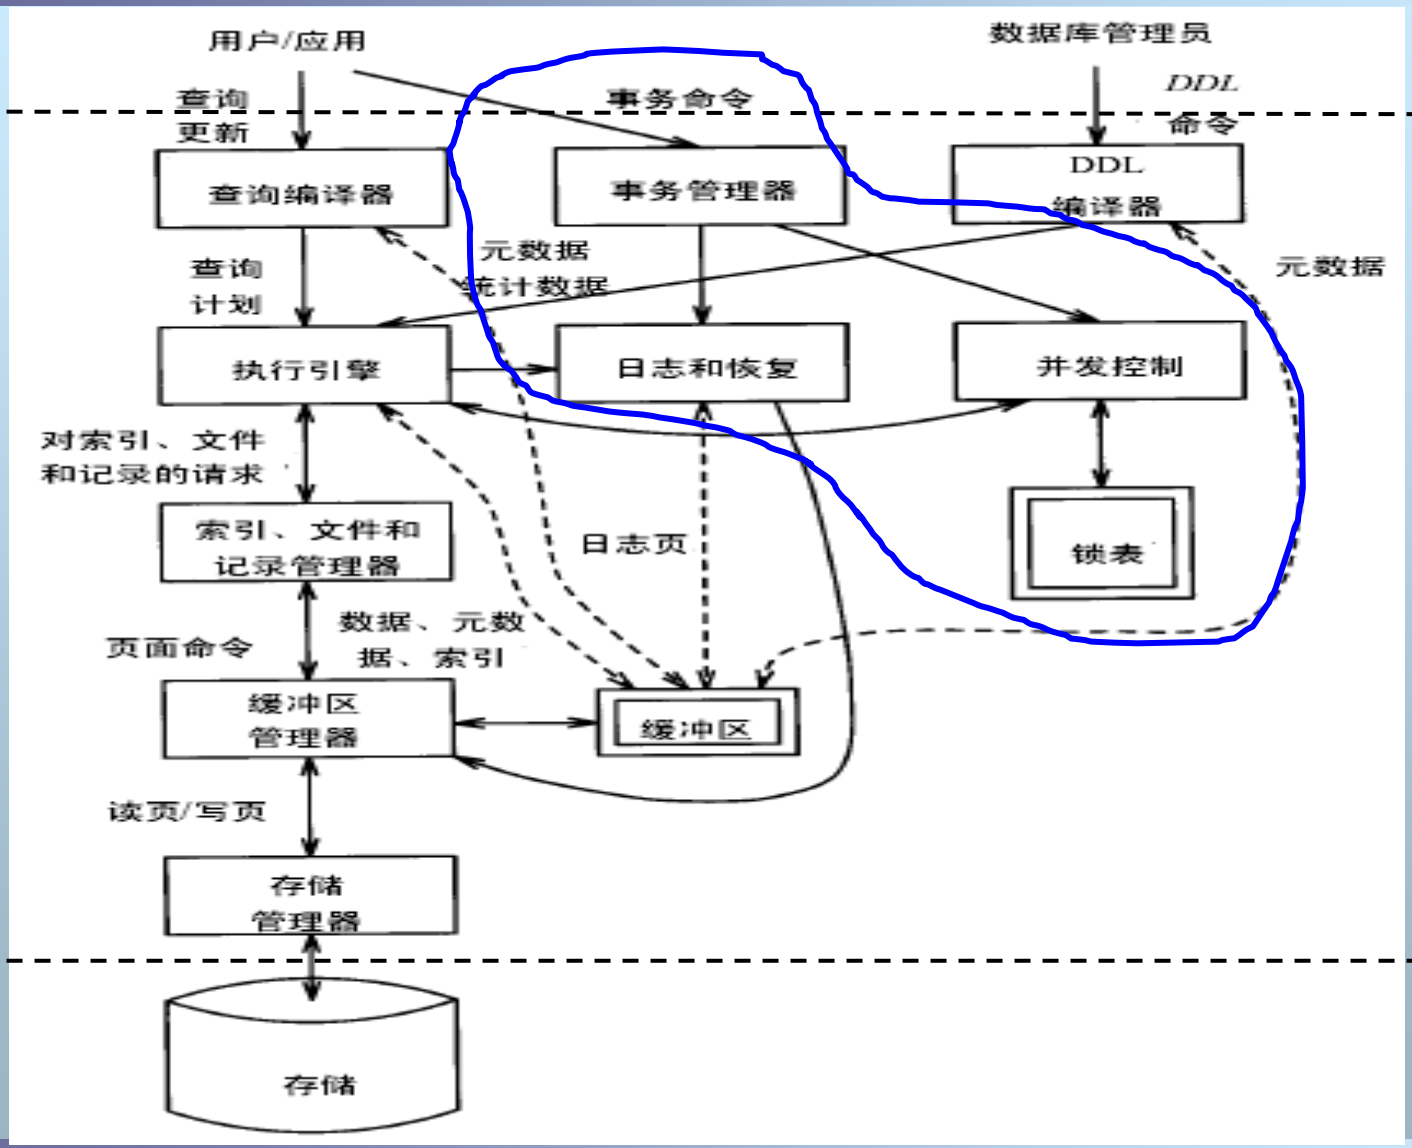
用户/应用
数据库管理员
查询
更新
事务命令
DDL
命令
查询编译器
事务管理器
DDL
编译器
元数据
统计数据
元数据
查询
计划
执行引擎
日志和恢复
并发控制
对索引、文件
和记录的请求
索引、文件和
记录管理器
日志页
锁表
数据、元数
据、索引
页面命令
缓冲区
管理器
缓冲区
读页/写页
存储
管理器
存储
用户
DBMS
数据库

二、数据库系统故障分析

- Consistency of DB 可能由于故障而被破坏
  - 事务故障
  - 介质故障
  - 系统故障

1、事务故障

- 发生在单个事务内部的故障
  - 可预期的事务故障
    - 即应用程序可以发现的故障，如转帐时余额不足。由应用程序处理
  - 非预期的事务故障
    - 如运算溢出等，导致事务被异常中止。应用程序无法处理此类故障，由系统进行处理

2、介质故障

- 硬故障（Hard Crash），一般指磁盘损坏
  - 导致磁盘数据丢失，破坏整个数据库

3、系统故障

- 系统故障：软故障（Soft Crash），由于OS、DBMS软件问题或断电等问题导致内存数据丢失，但磁盘数据仍在
  - 影响所有正在运行的事务，破坏事务状态，但不破坏整个数据库

4、数据库系统故障恢复策略

- 目的
  - 恢复DB到最近的一致状态
- 基本原则
  - 冗余（Redundancy）
- 实现方法
  - 定期备份整个数据库
  - 建立事务日志 (log)
  - 通过备份和日志进行恢复

4、数据库系统故障恢复策略

The recovery process

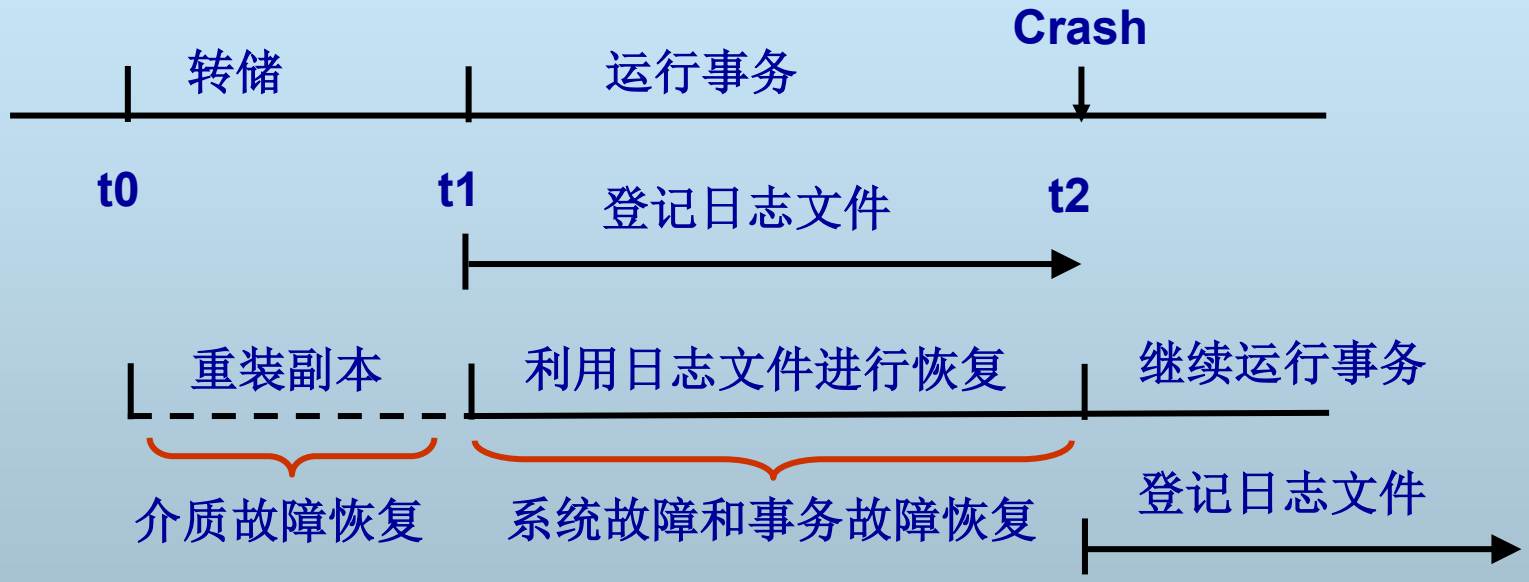

当发生故障时：

（1）若是介质故障，则首先重装副本

（2）利用日志进行事务故障恢复和系统故障恢复，一直恢复到故障发生点

三、Undo日志

- 事务日志记录了所有更新操作的具体细节
  - Undo日志、Redo日志、Undo/Redo日志
- 日志文件的登记严格按事务执行的时间次序
- Undo日志文件中的内容
  - 事务的开始标记（<Start T>）
  - 事务的结束标记（<Commit, T>或<Abort T>）
  - 事务的更新操作记录，一般包括以下内容
    - 执行操作的事务标识
    - 操作对象
    - 更新前值（插入为空）

1、Undo日志规则

- 事务的每一个修改操作都生成一个日志记录<T,x, old-value>
- 在x被写到磁盘之前，对应此修改的日志记录必须已被写到磁盘上
- 当事务的所有修改结果都已写入磁盘后，将<Commit,T>日志记录写到磁盘上

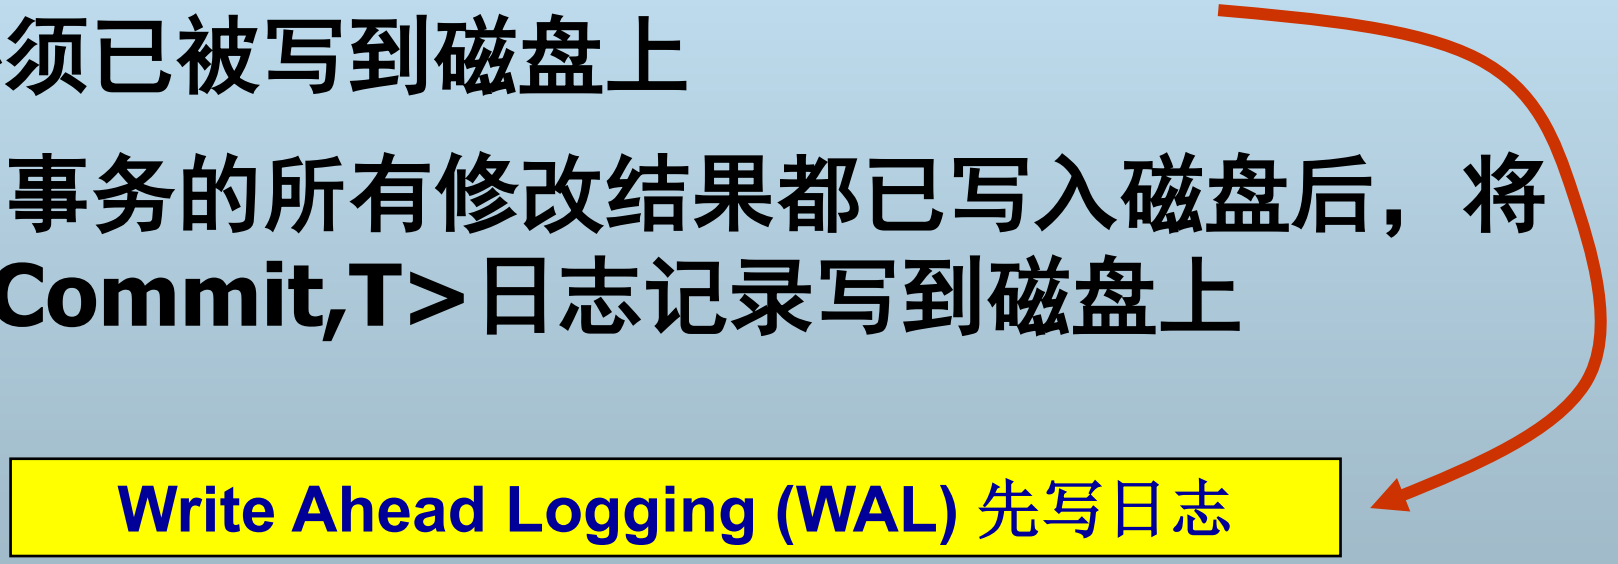

先写日志(Write-Ahead Log)原则

- 在数据被写到磁盘之前，对应此修改的日志记录必须已被写到磁盘上

先写日志

<T1, Begin Transaction>

<T1,A,1000,900>

后写日志

<T1, Begin Transaction>

设T1将A修改为900时发生故障。设此时900已写到数据库，但还未来得及写到日志中。

根据恢复策略，T1在恢复应UNDO，但此时由于后写日志，A的更新操作在日志中没有记录，因此无法将A恢复到1000

如果先写日志，则即使没有写到数据库中，也只不过多执行一次UNDO操作，不会影响数据库的一致性。

1、Undo日志规则

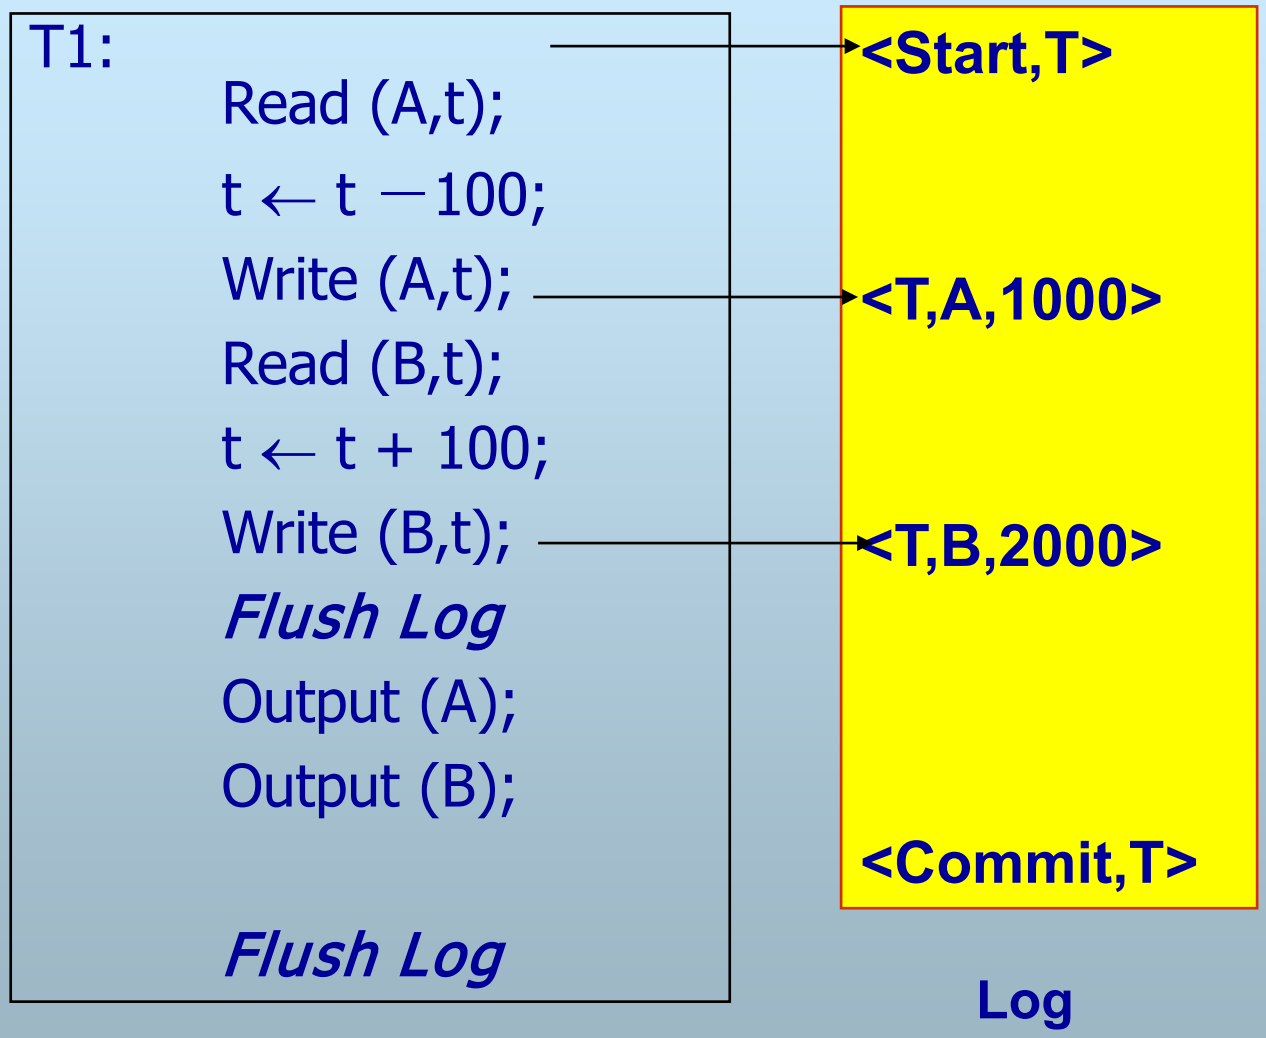

Initial:
A=1000
B=2000

1、Undo日志规则

T1:

Read (A,t);

t ← t －100;

Write (A,t);

Read (B,t);

t ← t + 100;

Write (B,t);

Flush Log

Output (A);

Output (B);

Flush Log

Fail here

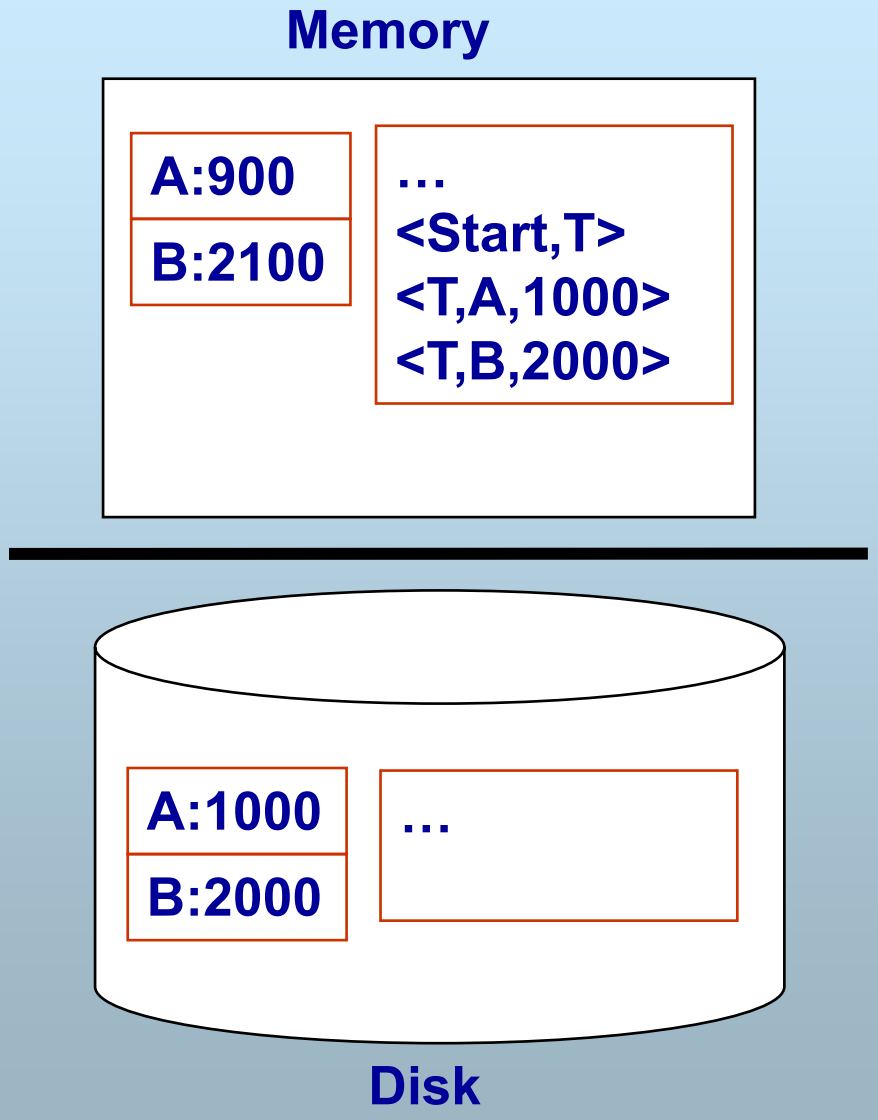

1、Undo日志规则

T1:

Read (A,t);

t ← t －100;

Write (A,t);

Read (B,t);

t ← t + 100;

Write (B,t);

Flush Log

Output (A);

Output (B);

Fail here

Flush Log

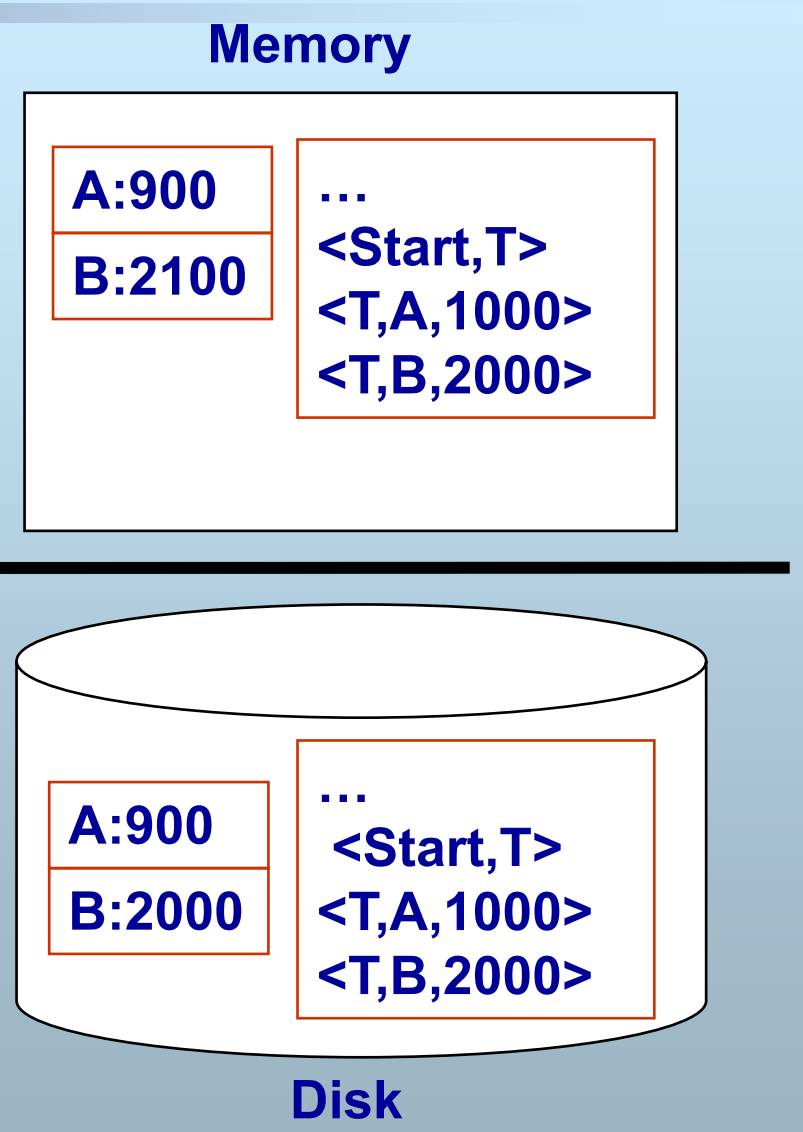

1、Undo日志规则

T1:

Read (A,t);

t ← t －100;

Write (A,t);

Read (B,t);

t ← t + 100;

Write (B,t);

Flush Log

Output (A);

Output (B);

Flush Log

Fail here

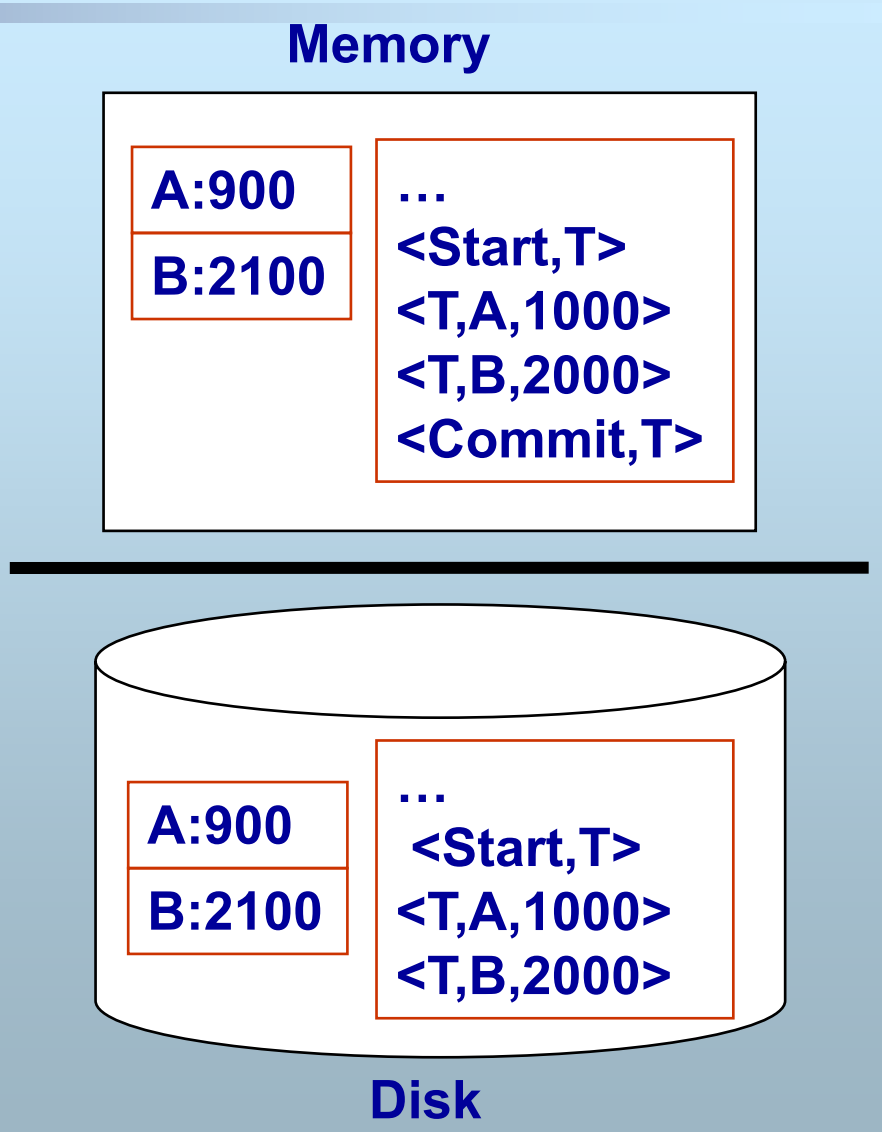

1、Undo日志规则

T1:

Read (A,t);

t ← t －100;

Write (A,t);

Read (B,t);

t ← t + 100;

Write (B,t);

Flush Log

Output (A);

Output (B);

Flush Log

Success!

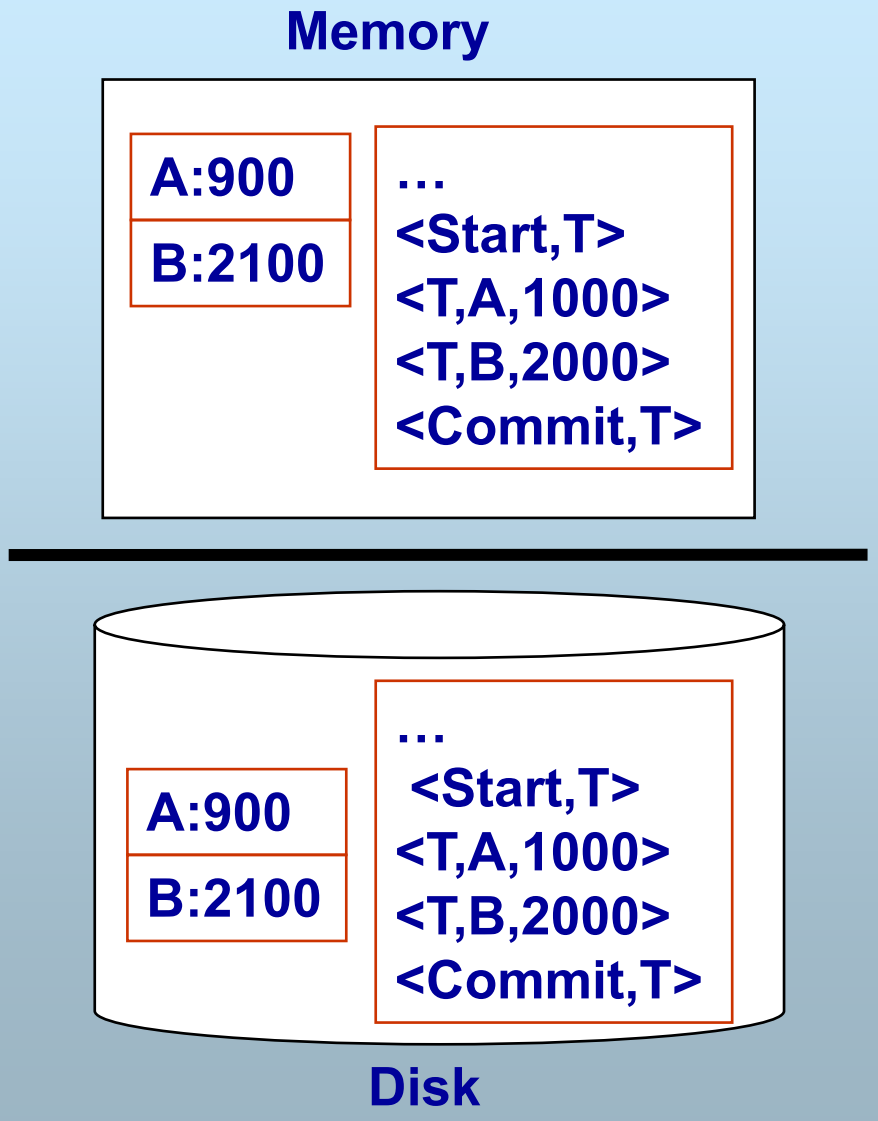

2、基于Undo日志的恢复

The recovery process

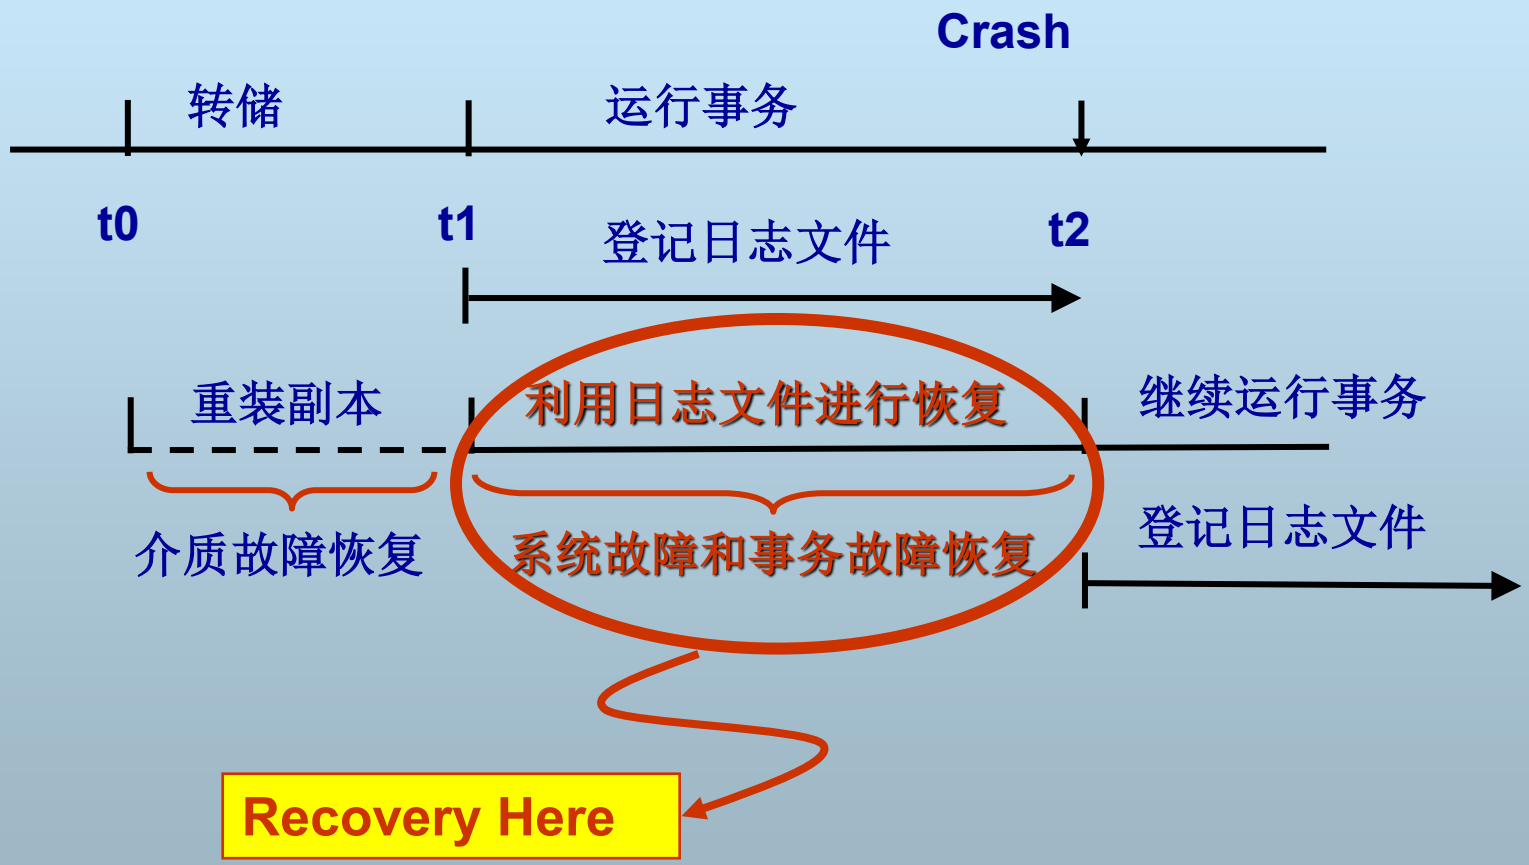

2、基于Undo日志的恢复

- 从头扫描日志，找出所有没有<Commit,T>或<Abort,T>的所有事务，放入一个事务列表L中
- 从尾部开始扫描日志记录<T,x,v>,如果T∈ L，则
  - write (X, v)
  - output (X)
- For each T∈ L do
  - write <Abort,T > to log

2、基于Undo日志的恢复

T1:

Read (A,t);

t ← t －100;

Write (A,t);

Read (B,t);

t ← t + 100;

Write (B,t);

Flush Log

Output (A);

Output (B);

Flush Log

Fail here

无须恢复！

Memory

A:900

B:2100

…

<Start,T>

<T,A,1000>

<T,B,2000>

A:1000

B:2000

…

Disk

2、基于Undo日志的恢复

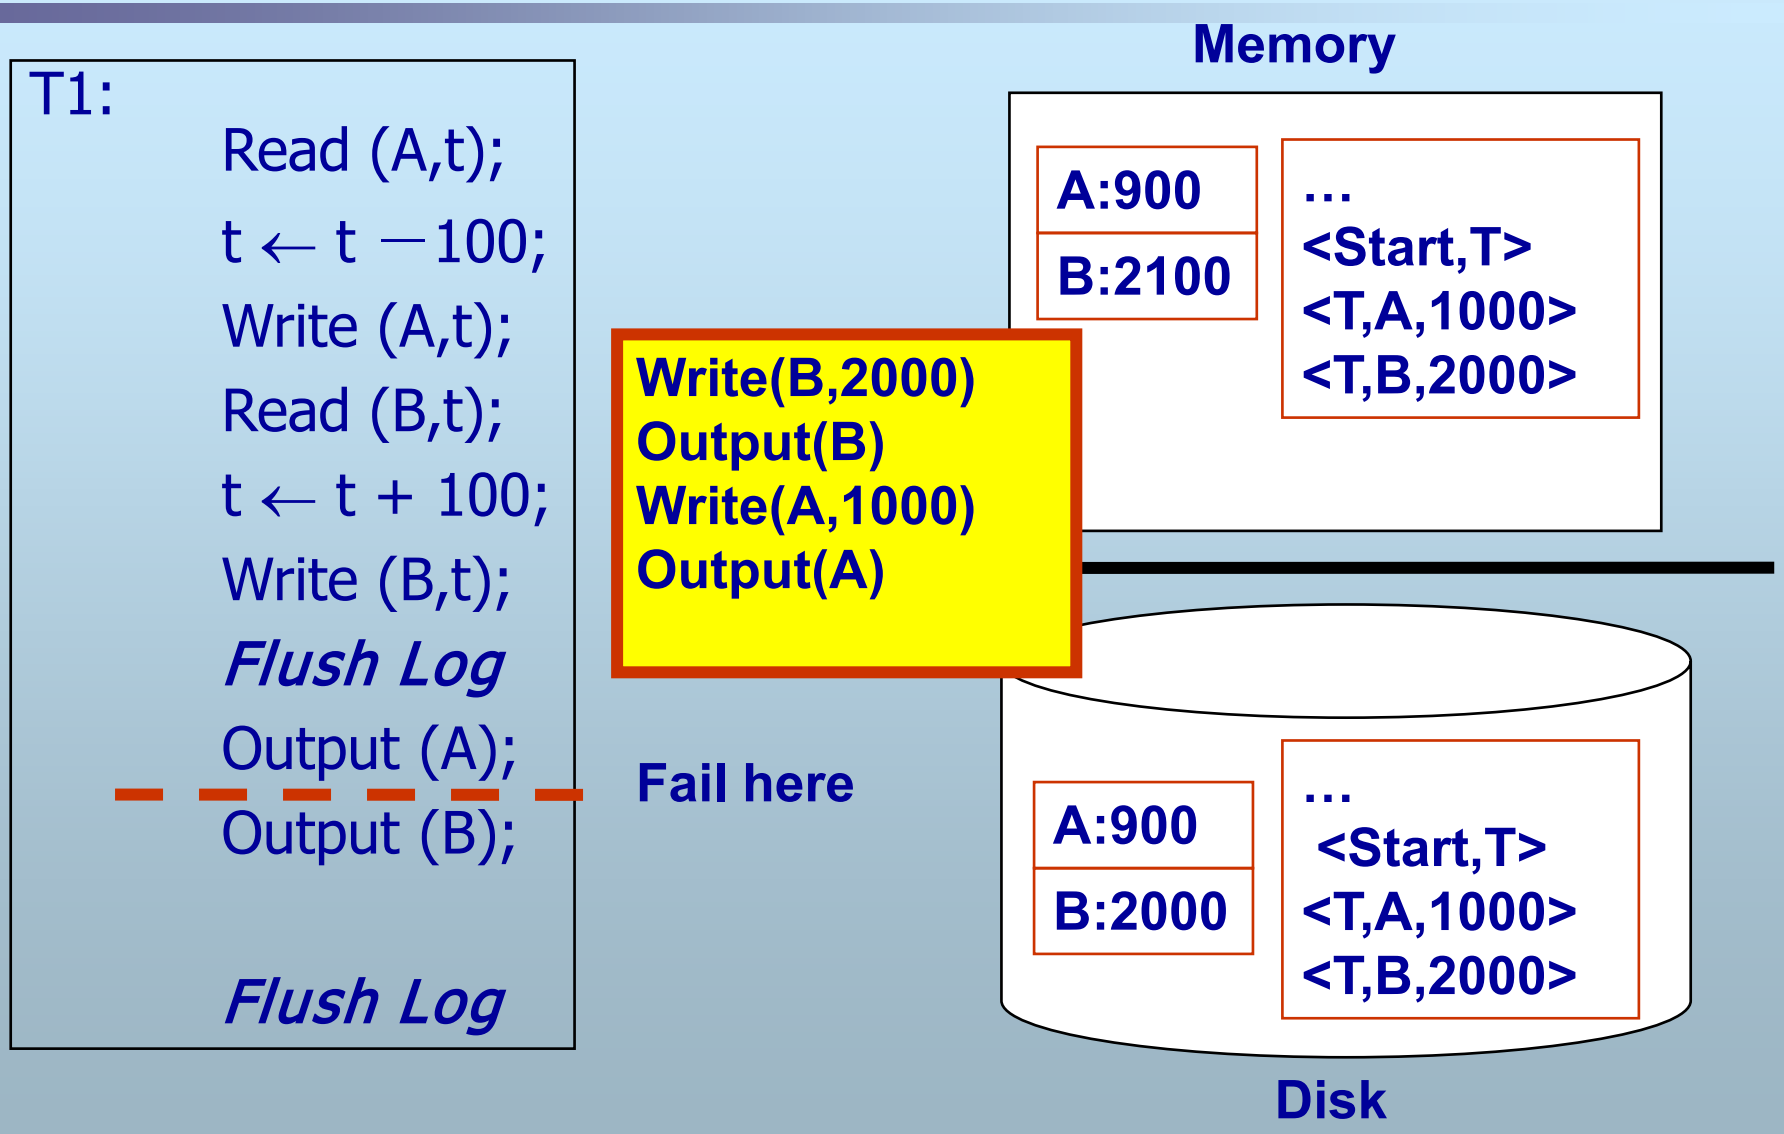

2、基于Undo日志的恢复

- **What if failure during recovery?**

No problem！
Just re-execute the recovery!
Because each recovery has same effect!

3、Undo日志总结

- <T,x,v>记录修改前的旧值
- 写入<Commit,T>之前必须先将数据写入磁盘
- 恢复时忽略已提交事务，只撤销未提交事务
  - 有<Commit,T>的事务肯定已写回磁盘

四、Redo日志

- 在x被写到磁盘之前，对应该修改的Redo日志记录必须已被写到磁盘上 (WAL)
- 在数据写回磁盘前先写<Commit,T>日志记录
- 日志中的数据修改记录
  - <T, x, *v*> - - Now *v* is the new value

1、Redo日志规则

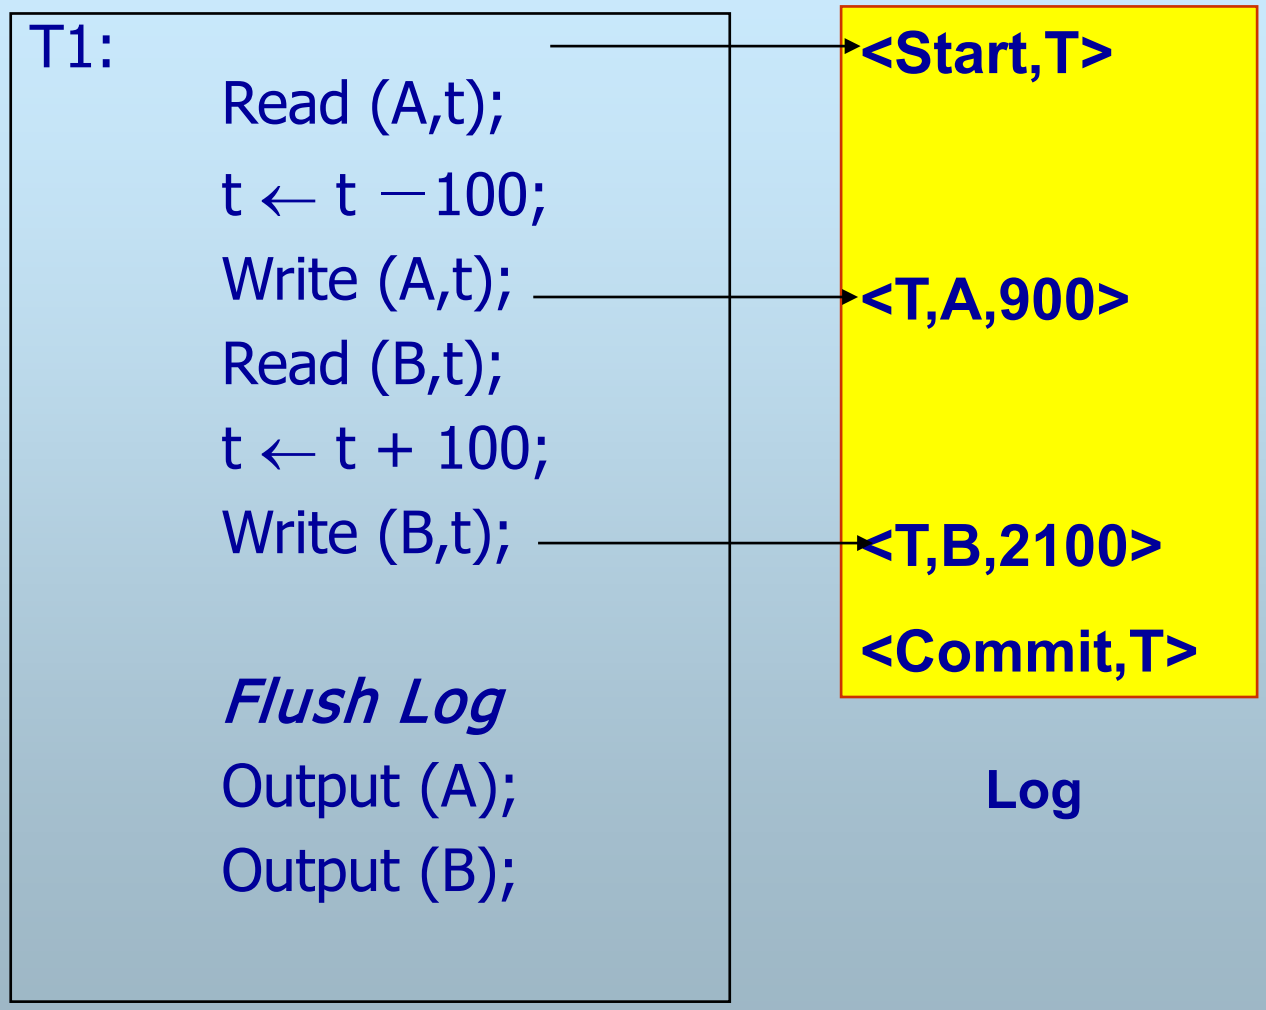
T1:
Read (A,t);
t ← t －100;
Write (A,t);
Read (B,t);
t ← t + 100;
Write (B,t);
Flush Log
Output (A);
Output (B);
<Start,T>
<T,A,900>
<T,B,2100>
<Commit,T>
Log
Initial:
A=1000
B=2000

1、Redo日志规则

T1:

Read (A,t);

t ← t －100;

Write (A,t);

Read (B,t);

t ← t + 100;

Write (B,t);

Flush Log

Output (A);

Output (B);

Fail here

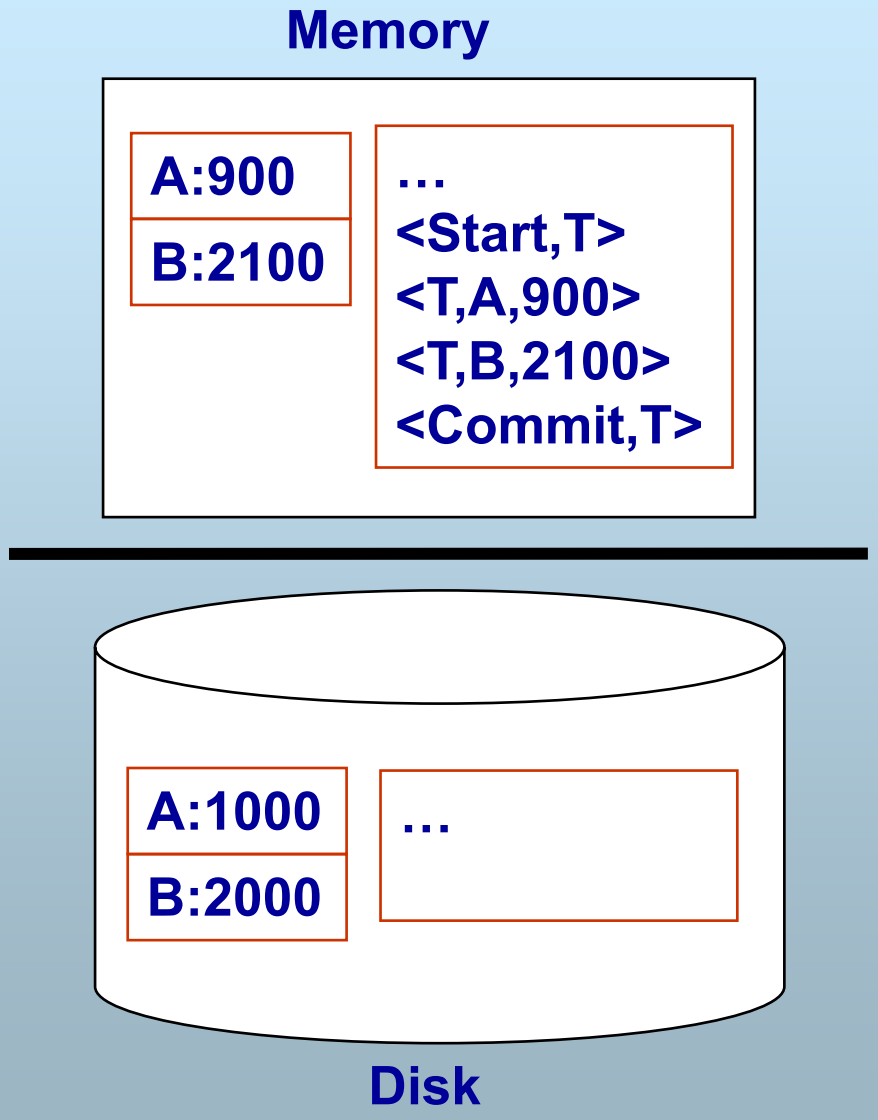

1、Redo日志规则

T1:

Read (A,t);

t ← t －100;

Write (A,t);

Read (B,t);

t ← t + 100;

Write (B,t);

Flush Log

Output (A);

Output (B);

Fail here

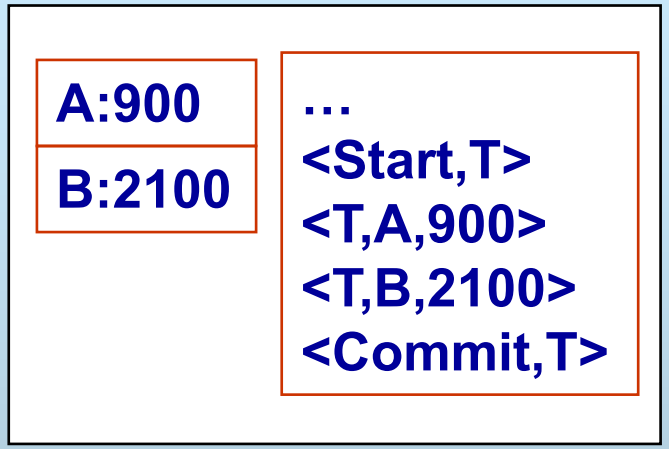

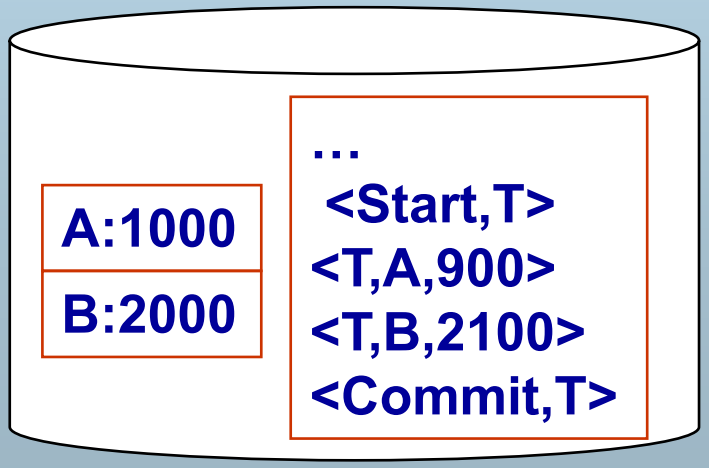

Disk

1、Redo日志规则

T1:

Read (A,t);

t ← t －100;

Write (A,t);

Read (B,t);

t ← t + 100;

Write (B,t);

Flush Log

Output (A);

Output (B);

Fail here

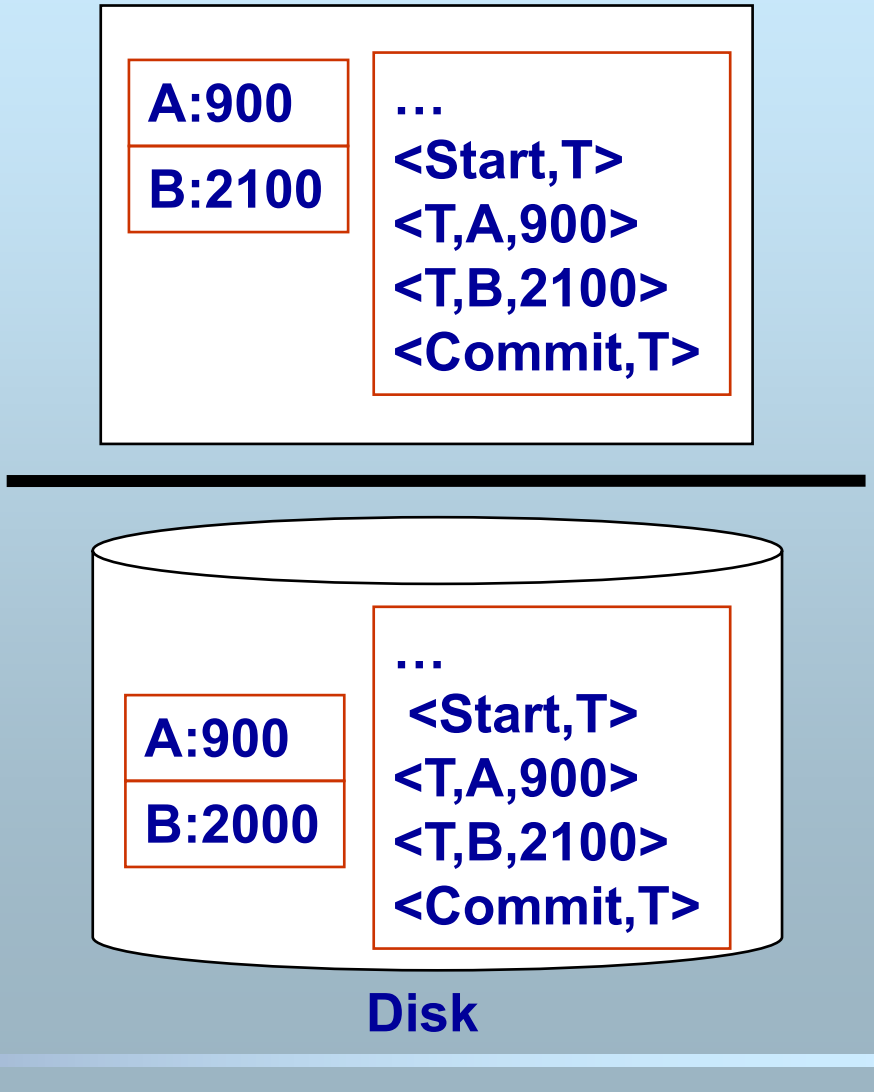

1、Redo日志规则

T1:

Read (A,t);

t ← t －100;

Write (A,t);

Read (B,t);

t ← t + 100;

Write (B,t);

Flush Log

Output (A);

Output (B);

Fail here

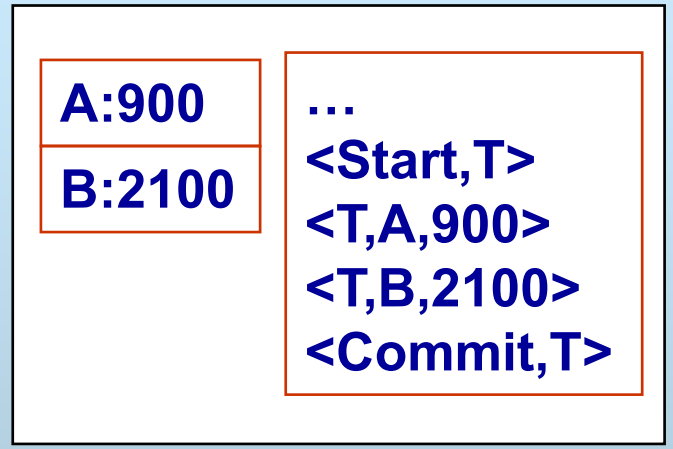

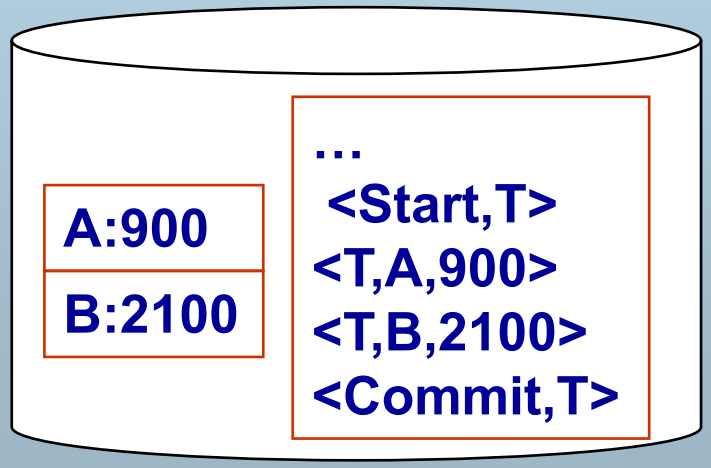

Disk

2、基于Redo日志的恢复

- 从头扫描日志，找出所有有<Commit,T>的事务，放入一个事务列表L中
- 从首部开始扫描日志记录<T,x,v>,如果T∈ L，则
  - write (X, v)
  - output (X)
- For each T∉ L do
  - write <Abort,T > to log

2、基于Redo日志的恢复

- 恢复的基础
  - 没有<Commit,T>记录的操作必定没有改写磁盘数据，因此在恢复时可以不理会
    - Differ from Undo logging
  - 有<Commit,T>记录的结果可能还未写回磁盘，因此在恢复时要Redo
    - Still differ from Undo logging

3、Undo vs. Redo

- Undo基于立即更新 (Immediate Update)
- Redo基于延迟更新 (Deferred Update)

3、Undo vs. Redo

- **Undo:** 立即更新（乐观）

```
T1:
        Read (A,t);
        t ← t －100;
        Write (A,t);
        Output (A);
        Read (B,t);
        t ← t + 100;
        Write (B,t);
        Output (B);
```


内存代价小


恢复代价高

- **Redo:** 延迟更新（悲观）

```
T1:
        Read (A,t);
        t ← t －100;
        Write (A,t);
        Read (B,t);
        t ← t + 100;
        Write (B,t);
        Output (A);
        Output (B);
```


恢复代价小


内存代价高

五、Undo/Redo日志

- 在x被写到磁盘之前，对应该修改的日志记录必须已被写到磁盘上 (WAL)
- 日志中的数据修改记录
  - <T, x, *v*, *w*>
    - - v is the old value, w is the new value
- 可以立即更新，也可以延迟更新

1、基于Undo/Redo日志的恢复

- 正向扫描日志，将<commit>的事务放入Redo列表中，将没有结束的事务放入Undo列表
- 反向扫描日志，对于<T,x,v,w>，若T在Undo列表中，则
  - Write(x,v); Output(x)
- 正向扫描日志，对于<T,x,v,w>，若T在Redo列表中，则
  - Write(x,w)； Output(x)
- 对于Undo列表中的T，写入<abort,T>

1、基于Undo/Redo日志的恢复

发生故障时的日志

<Start,T1>

<T1,B,2000,1900>

<Start,T2>

<T2,A,1000,900>

<Commit,T1>

<Start,T3>

<T3,C,3000,2000>

<T3,B,1900,1800>

<Commit,T2>

<Start,T4>

<T4,D,1000,1200>

1. Undo列表 {T3,T4}; Redo {T1,T2}
2. Undo
   T4: D=1000
   T3: B=1900
   T3: C=3000
3. Redo
   T1:B=1900
   T2:A=900
4. Write log
   <Abort,T3>
   <Abort,T4>

1、基于Undo/Redo日志的恢复

- 先Undo后Redo

发生故障时的日志

<Start,T1>

<Start,T2>

<T1,A,1000,1200>

<T2,A,1000,1100>

< Commit,T2>

T1要UNDO，T2要REDO

如果先REDO，则A＝1100；然后在UNDO，A＝1000。不正确

先UNDO，A＝1000；然后REDO，A＝1100。正确

六、检查点(Checkpoint)

- 当系统故障发生时，必须扫描日志。需要搜索整个日志来确定UNDO列表和REDO列表
  - 搜索过程太耗时，因为日志文件增长很快
  - 会导致最后产生的REDO列表很大，使恢复过程变得很长

1、Simple Checkpoint

Periodically:

(1) Do not accept new transactions

(2) Wait until all transactions finish (commit/abort)

(3) Flush all log records to disk (log)

(4) Flush all buffers to disk (DB)

(5) Write "checkpoint" record on disk (log)

(6) Resume transaction processing

2、Checkpoint-Based Recovery

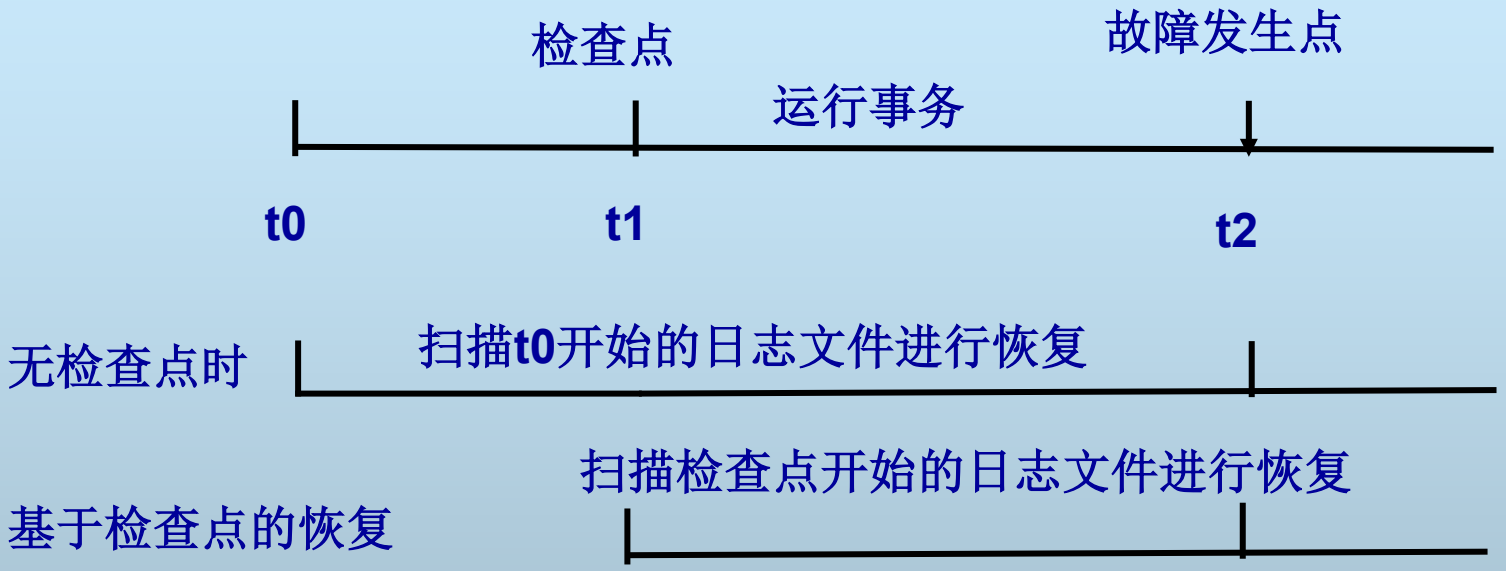

检查点技术保证检查点之前的所有commit操作的结果已写回数据库，在恢复时不需REDO

2、Checkpoint-Based Recovery

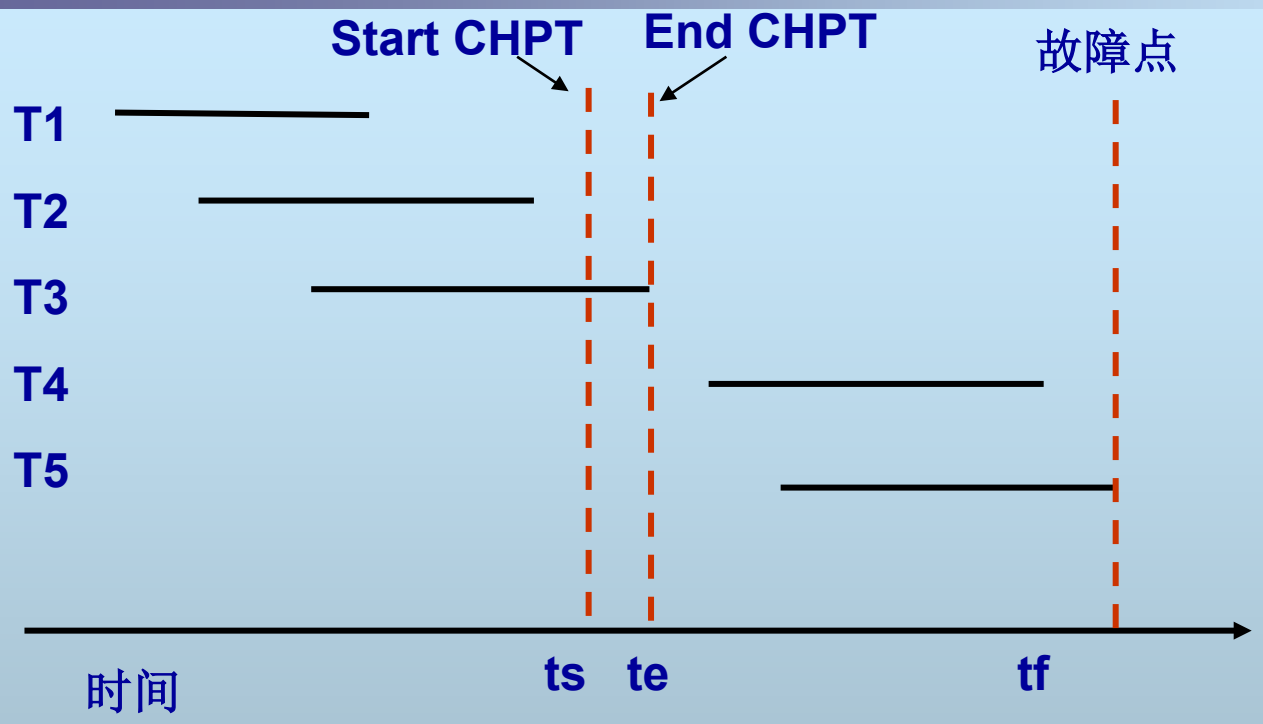

恢复时：UNDO＝{T5}, REDO＝{T4}

T1、T2和T3由于在检查点之前已Commit
因此不需要REDO

Log

<start,T1>
…
<start,T2>
…
<start,T3>
…
<commit,T1>
…
<abort,T2>
…
<commit,T3>
<checkpoint>
<start,T4>
…
<start,T5>
…
<commit,T4>
…

七、日志轮转技术

- 数据库日志产生很快，会占用很多的磁盘存储。但大部分日志随时间推移实际上已经失效了
- 采用Log Rotation节省存储

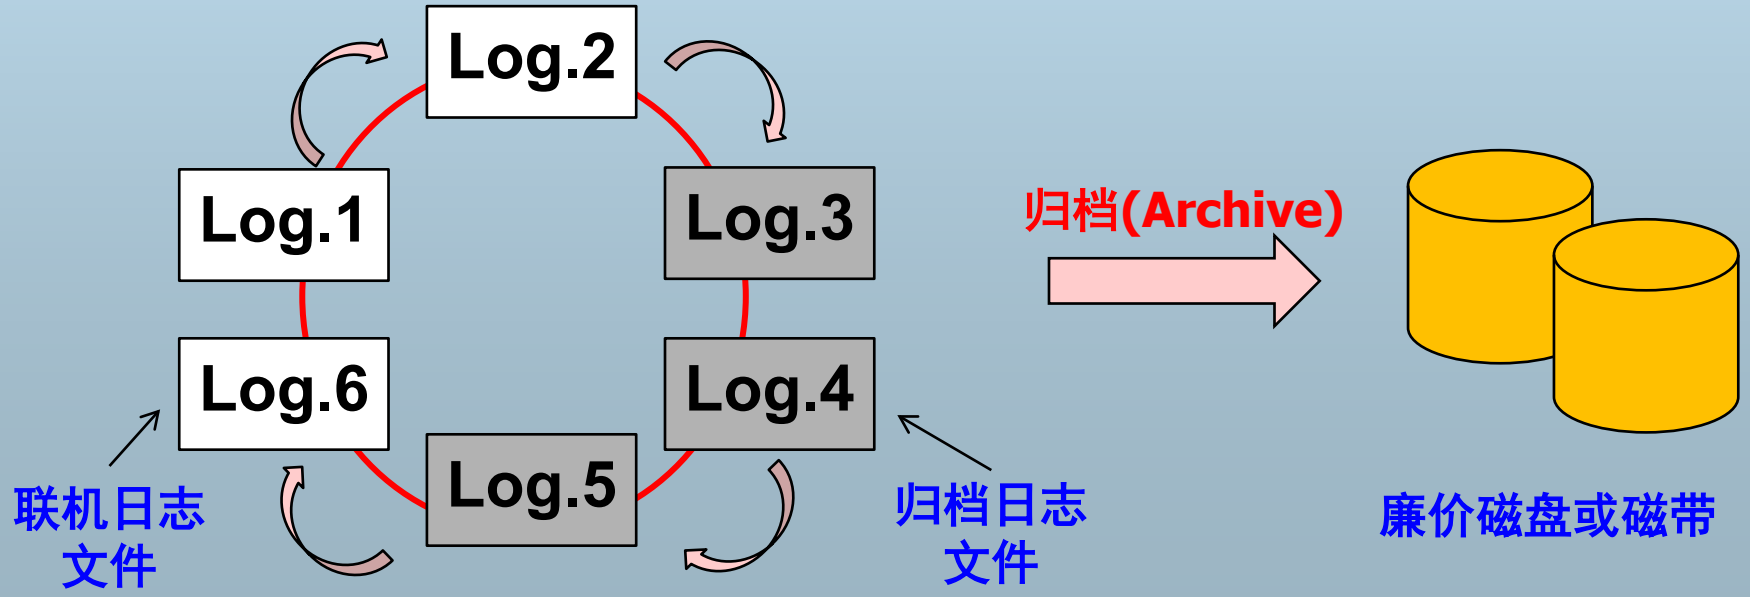

本章小结

- 事务
- 数据库一致性
- 数据库系统故障分析
- Undo日志
- Redo日志
- Undo/Redo日志
- Checkpoint
- 日志轮转技术